

Budowa modelu ekonometrycznego na podstawie danych makroekonomicznych USA w latach 1980-2022

Natalia Nowak, Jacek Rybak

2026-06-13

Opis danych i źródło

Źródło i opis

Zbiór danych pochodzi ze strony kaggle.com i zawiera dane makroekonomiczne z USA zbierane od listopada 1980 roku do maja 2022.

Podstawowe charakterystyki zmiennych







`summary(dane)`

```
##          date          CPI      Mortgage_rate      Unemp_rate
## Min.   :1980-11-01  Min.   : 85.6    Min.   : 2.684    Min.   : 3.500
## 1st Qu.:1991-03-16  1st Qu.:134.9    1st Qu.: 4.519    1st Qu.: 4.900
## Median :2001-08-01  Median :177.4    Median : 6.834    Median : 5.700
## Mean   :2001-07-31  Mean   :178.8    Mean   : 7.421    Mean   : 6.181
## 3rd Qu.:2011-12-16  3rd Qu.:227.5    3rd Qu.: 9.338    3rd Qu.: 7.250
## Max.   :2022-05-01  Max.   :291.5    Max.   :18.454    Max.   :14.700
##      NASDAQ      disposable_income Personal_consumption_expenditure
## Min.   : 167.4    Min.   : 4965    Min.   : 1827
## 1st Qu.: 479.5    1st Qu.: 6861    1st Qu.: 3910
## Median :1884.7    Median : 9734    Median : 7082
## Mean   :2726.4    Mean   : 9802    Mean   : 7626
## 3rd Qu.:3131.4    3rd Qu.:12226    3rd Qu.:10857
## Max.   :15814.9    Max.   :19120    Max.   :16955
## personal_savings
## Min.   : 2.100
## 1st Qu.: 5.850
## Median : 7.200
## Mean   : 7.487
## 3rd Qu.: 8.600
## Max.   :33.800
```

- `date` data danej obserwacji
- X_1 : CPI wskaźnik cen towarów i usług konsumpcyjnych dla ludności miejskiej
- X_2 :Mortgage_rate średnie oprocentowanie 30-letnich kredytów hipotecznych o stałej stopie procentowej


- X_3 :Unemp_rate stopa bezrobocia
- X_4 :NASDAQ wartość indeksu NASDAQ
- X_5 :disposable_income dochód rozporządzalny
- X_6 :Personal_consumption_expenditure wydatki na konsumpcję
- Y :personal_savings odsetek wynagrodzenia przeznaczany na oszczędności

Wykresy zależności



Badanie korelacji między zmiennymi

```
train |>
  select(-date) |>
  cor() |>
  corrplot()
```



```
corr_matrix <- train |>
  select(-c(date, personal_savings)) |>
  cor()

pary_kor <- corr_matrix |>
  as.data.frame() |>
  mutate(var1 = rownames(corr_matrix)) |>
  pivot_longer(cols = -var1, names_to = "var2", values_to = "corr") |>
  filter(var1 < var2, abs(corr) > 0.7) |>
  arrange(desc(abs(corr)))

print(pary_kor)
```

```
## # A tibble: 10 x 3
##   var1                var2                corr
##   <chr>              <chr>              <dbl>
## 1 disposable_income Personal_consumption_expenditure 0.996
## 2 CPI                disposable_income          0.993
## 3 CPI                Personal_consumption_expenditure 0.993
## 4 CPI                Mortgage_rate          -0.913
## 5 disposable_income Mortgage_rate          -0.894
## 6 Mortgage_rate      Personal_consumption_expenditure -0.877
## 7 disposable_income NASDAQ                0.872
## 8 NASDAQ             Personal_consumption_expenditure 0.866
```

```
## 9 CPI NASDAQ 0.864
## 10 Mortgage_rate NASDAQ -0.748
```

W niektórych parach zmiennych objaśniających występują wysokie korelacje. Przed zbudowaniem modelu należy pozbyć się zmiennych objaśniających o wysokim stopniu korelacji ze sobą.

```
train <- train |>
  select(-c(CPI, disposable_income))

corr_matrix <- train |>
  select(-c(date, personal_savings)) |>
  cor()

pary_kor <- corr_matrix |>
  as.data.frame() |>
  mutate(var1 = rownames(corr_matrix)) |>
  pivot_longer(cols = -var1, names_to = "var2", values_to = "corr") |>
  filter(var1 < var2, abs(corr) > 0.7) |>
  arrange(desc(abs(corr)))

print(pary_kor)
```

```
## # A tibble: 3 x 3
##   var1      var2      corr
##   <chr>    <chr>    <dbl>
## 1 Mortgage_rate Personal_consumption_expenditure -0.877
## 2 NASDAQ      Personal_consumption_expenditure  0.866
## 3 Mortgage_rate NASDAQ -0.748
```

Po usunięciu zmiennych CPI oraz disposable_income żadna wartość bezwzględna korelacji zmiennych nie przekracza wartości 0,9.

```
cor(train |>
  select(-c(date, personal_savings)),
  train$personal_savings)
```

```
##           [,1]
## Mortgage_rate 0.7547712
## Unemp_rate    0.5522970
## NASDAQ        -0.6924020
## Personal_consumption_expenditure -0.7084381
```

Wszystkie zmienne są umiarkowanie lub silnie skorelowane ze zmienną objaśnianą.

Badanie stacjonarności zmiennych

```
train |>
  summarise(across(where(is.numeric), ~ kpss.test(.x, null = "Trend")$p.value))
```

```
## Mortgage_rate Unemp_rate NASDAQ Personal_consumption_expenditure
## 1          0.01          0.01    0.01                      0.01
## personal_savings
## 1          0.01
```

Zmienne nie są stacjonarne nawet po uwzględnieniu trendu. W celu usunięcia niestacjonarności przekształcamy szereg czasowy wartości w szereg czasowy różnic wartości.


```
train <- train |>
  mutate(across(where(is.numeric), ~ c(NA, diff(.x)))) |>
  slice(-1)

train |>
  select(-date) |>
  summarise(across(everything(), ~ kpss.test(.x, null = "Trend")$p.value))
```

```
## Mortgage_rate Unemp_rate NASDAQ Personal_consumption_expenditure
## 1          0.1          0.1    0.1                      0.07523593
## personal_savings
## 1          0.1
```

Po przekształceniu zmienne stały się stacjonarne z wyjątkiem zmiennej opisującej wydatki na konsumpcję.

```
ggplot(train, aes(x = date, y = Personal_consumption_expenditure)) +
  geom_line() +
  theme_minimal()
```



```
#https://metricgate.com/docs/zivot-andrews-test/
summary(ur.za(train$Personal_consumption_expenditure))
```

```
##
## #####
## # Zivot-Andrews Unit Root Test #
## #####
##
##
## Call:
## lm(formula = testmat)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -177.395  -11.061    1.661   13.036  157.344
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  10.29188    3.19632   3.220  0.00139 **
## y.l1         -0.10286    0.05018  -2.050  0.04103 *
## trend         0.10544    0.01711   6.164 1.76e-09 ***
## du          -25.69084    5.15304  -4.986 9.28e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 28.6 on 394 degrees of freedom
## (1 observation deleted due to missingness)
## Multiple R-squared:  0.09088,    Adjusted R-squared:  0.08395
## F-statistic: 13.13 on 3 and 394 DF,  p-value: 3.46e-08
##
##
## Teststatistic: -21.9789
## Critical values: 0.01= -5.34 0.05= -4.8 0.1= -4.58
##
## Potential break point at position: 331
```

Po przyjrzeniu się wykresowi można zauważyć silny spadek wydatków w okolicy kryzysu z 2008 roku. Ze względu na niego szereg nawet po różnicowaniu nie jest uznawany za stacjonarny przez test KPSS. Na szczęście istnieje test stacjonarności, który potrafi uwzględnić pęknięcie strukturalne. Jest to test Zivota-Andrewsa. Odrzucamy H_0 : szereg jest niestacjonarny i nie ma pęknięć strukturalnych, a przyjmujemy H_1 : szereg jest stacjonarny z pęknięciem strukturalnym w określonym punkcie czasu (w tym przypadku jest to jesień 2008 roku).

Budowa modelu

```
model <- lm(personal_savings ~ Mortgage_rate + Unemp_rate + NASDAQ +
             Personal_consumption_expenditure, train)
summary(model)
```

```
##
```

```
## Call:
## lm(formula = personal_savings ~ Mortgage_rate + Unemp_rate +
##     NASDAQ + Personal_consumption_expenditure, data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.2989 -0.2243  0.0164  0.2378  4.8257
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.2530737   0.0485474    5.213 3.01e-07 ***
## Mortgage_rate    0.2213478   0.1483426    1.492   0.136
## Unemp_rate     -0.2027141   0.2225446   -0.911   0.363
## NASDAQ          0.0003841   0.0003394    1.132   0.258
## Personal_consumption_expenditure -0.0107761   0.0012957  -8.316 1.49e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7398 on 394 degrees of freedom
## Multiple R-squared:  0.154, Adjusted R-squared:  0.1455
## F-statistic: 17.94 on 4 and 394 DF, p-value: 1.526e-13
```

Pierwotny model wyjaśnia 15.4% zmienności zmiennej objaśnianej, a jego niskie p-value na poziomie $1.5260314 \times 10^{-13}$ oznacza, że zmienne objaśniające mają istotny statystycznie wpływ na zmienną objaśnianą.

Eliminacja zmiennych metodą krokową wsteczną

Nie wszystkie zmienne, które są zawarte w modelu, są istotne. Dlatego po kolei będzie eliminowana zmienna o najniższej istotności aż do momentu, w którym wszystkie zmienne będą istotne.

```
model <- lm(personal_savings ~ Mortgage_rate + NASDAQ +
             Personal_consumption_expenditure, train)
summary(model)

##
## Call:
## lm(formula = personal_savings ~ Mortgage_rate + NASDAQ + Personal_consumption_expenditure,
##     data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.3265 -0.2301  0.0219  0.2394  4.7368
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.2508824   0.0484774    5.175 3.63e-07 ***
## Mortgage_rate    0.2380181   0.1471777    1.617   0.107
## NASDAQ          0.0003888   0.0003393    1.146   0.253
## Personal_consumption_expenditure -0.0106552   0.0012887  -8.268 2.09e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



```
##
## Residual standard error: 0.7396 on 395 degrees of freedom
## Multiple R-squared:  0.1523, Adjusted R-squared:  0.1458
## F-statistic: 23.65 on 3 and 395 DF,  p-value: 4.264e-14

model <- lm(personal_savings ~ Mortgage_rate +
             Personal_consumption_expenditure, train)
summary(model)

##
## Call:
## lm(formula = personal_savings ~ Mortgage_rate + Personal_consumption_expenditure,
##     data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.2989 -0.2276  0.0209  0.2302  4.7623
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      0.245508   0.048269   5.086 5.65e-07 ***
## Mortgage_rate      0.244590   0.147124   1.662  0.0972 .
## Personal_consumption_expenditure -0.010271   0.001245  -8.252 2.34e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.7399 on 396 degrees of freedom
## Multiple R-squared:  0.1494, Adjusted R-squared:  0.1452
## F-statistic: 34.79 on 2 and 396 DF,  p-value: 1.205e-14
```


W takiej postaci wszystkie zmienne są istotne na poziomie $\alpha = 0.1$.

Badanie normalności rozkładu reszt

```
shapiro.test(model$residuals)

##
##  Shapiro-Wilk normality test
##
## data:  model$residuals
## W = 0.75487, p-value < 2.2e-16
```


Test Shapiro-Wilka odrzuca H_0 zatem uznaje, że reszty nie mają rozkładu normalnego.



Jednak po przyjrzeniu się wykresowi Q-Q możemy zauważyć, że większość błędów rozkłada się zgodnie z rozkładem normalnym. Jedynie ogony są grubsze ze względu na wartości odstające.

```
model_data_filtered <- model_data |>
  filter(between(.resid, mean(.resid)-2*sd(.resid), mean(.resid)+2*sd(.resid)))

ggplot(model_data_filtered, aes(sample = .resid)) +
  stat_qq() +
  stat_qq_line(color = "red") +
  theme_minimal() +
  labs(title = "Wykres Q-Q dla reszt")
```



Jeżeli odfiltrujemy wartości spoza przedziału $(\mu - 2\sigma, \mu + 2\sigma)$ to wciąż widoczne są lekkie odchylenia, lecz środkowy obszar rozkładu przylega do linii teoretycznej, dlatego można uznać ten rozkład za asymptotycznie normalny. W przedziale dwóch sigma zawiera się 383 z 399 obserwacji.

Testowanie autokorelacji

Test Durbina-Watsona

```
dwtest(model)
```

```
##
## Durbin-Watson test
##
## data:  model
## DW = 2.4754, p-value = 1
## alternative hypothesis: true autocorrelation is greater than 0
```

Statystyka testowa wynosi 2.474, p-value = 1, co oznacza brak podstaw do odrzucenia H_0 . Wartość statystyki jest powyżej 2, co może sugerować lekką autokorelację ujemną - do zweryfikowania innym testem.

Test Breuscha-Godfrey (opóźnienie do 12 miesięcy)

```
bgtest(model, order = 12)
```

```
##  
## Breusch-Godfrey test for serial correlation of order up to 12  
##  
## data: model  
## LM test = 42.964, df = 12, p-value = 2.29e-05
```

Bardzo niskie p-value, odrzucamy hipotezę zerową o braku autokorelacji do 12. rzędu. W resztach modelu istnieje silna autokorelacja.

```
model_pw <- prais_winsten(personal_savings ~ Mortgage_rate +  
  Personal_consumption_expenditure, data = train, index = "date")  
rho <- tail(model_pw$rho, 1)[[1]]  
train2 <- data.frame(personal_savings = numeric(nrow(train)),  
  Mortgage_rate = numeric(nrow(train)),  
  Personal_consumption_expenditure = numeric(nrow(train)))  
train2$intercept <- c(1 * sqrt(1 - rho^2), rep(1 - rho, nrow(train) - 1))  
train2$personal_savings <- train$personal_savings - lag(train$personal_savings, default = 0)*rho  
train2$Mortgage_rate <- train$Mortgage_rate - lag(train$Mortgage_rate, default = 0)*rho  
train2$Personal_consumption_expenditure <- train$Personal_consumption_expenditure - lag(train$Personal_  
train2$personal_savings[1] <- train$personal_savings[1]*sqrt(1-rho^2)  
train2$Mortgage_rate[1] <- train$Mortgage_rate[1]*sqrt(1-rho^2)  
train2$Personal_consumption_expenditure[1] <- train$Personal_consumption_expenditure[1]*sqrt(1-rho^2)  
model2 <- lm(personal_savings ~ Mortgage_rate + intercept +  
  Personal_consumption_expenditure - 1, data = train2)
```

Istnienie wysokiej autokorelacji jest problemem, który należy spróbować rozwiązać. W tym celu została zastosowana metoda Cochrane'a-Orcutta, a dokładniej zmodyfikowana wersja, która w literaturze jest określana mianem procedury Prais-Winstena.

```
bgtest(model2, order = 12)
```

```
##  
## Breusch-Godfrey test for serial correlation of order up to 12  
##  
## data: model2  
## LM test = 24.45, df = 12, p-value = 0.01765
```

Wynik testu się zmienił - p-value znacznie wzrosło do wartości 0.02, lecz wciąż jest ono poniżej poziomu $\alpha = 0.1$. Niestety próba pozbycia się autokorelacji zakończyła się niepowodzeniem.

Badanie heteroskedastyczności

Test Breuscha-Pagana

```
bptest(model)
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: model  
## BP = 6.1926, df = 2, p-value = 0.04522
```

Wartość $p\text{-value} = 0.0452$ jest mniejsza od przyjętego poziomu istotności $\alpha = 0.1$, co nakazuje odrzucić hipotezę zerową o homoskedastyczności. Oznacza to, że w modelu występuje problem heteroskedastyczności, czyli wariancja składnika losowego nie jest stała w czasie.

Test White'a

```
bptest(model, ~ fitted(model) + I(fitted(model)^2))
```

```
##  
## studentized Breusch-Pagan test  
##  
## data: model  
## BP = 2.87, df = 2, p-value = 0.2381
```

Wariancja testu oparta na kwadratach wartości dopasowanych dała wynik nieistotny statystycznie ($p\text{-value} = 0.2381 > 0.1$), co oznacza brak podstaw do odrzucenia hipotezy zerowej. Wynik ten sugeruje, że występująca w modelu heteroskedastyczność ma charakter liniowy względem samych zmiennych objaśniających, a nie form nieliniowych.

```
gqtest(model, order.by = ~ Personal_consumption_expenditure, data = train)
```

```
##  
## Goldfeld-Quandt test  
##  
## data: model  
## GQ = 1.4647, df1 = 197, df2 = 196, p-value = 0.003872  
## alternative hypothesis: variance increases from segment 1 to 2
```

```
gqtest(model, order.by = ~ Mortgage_rate, data = train)
```

```
##  
## Goldfeld-Quandt test  
##  
## data: model  
## GQ = 2.366, df1 = 197, df2 = 196, p-value = 1.454e-09  
## alternative hypothesis: variance increases from segment 1 to 2
```

W celu głębszej analizy struktury heteroskedastyczności przeprowadzono test Goldfelda-Quandta dla obu zmiennych objaśniających. Hipoteza zerowa zakłada stałość wariancji (homoskedastyczność), natomiast hipoteza alternatywna postuluje, że wariancja reszt rośnie wraz ze wzrostem wartości danej zmiennej.

- **Dla wydatków na konsumpcję:** wartość p -value = 0.0039 jest znacznie mniejsza od $\alpha = 0.1$, co nakazuje odrzucić hipotezę zerową.
- **Dla stopy kredytów hipotecznych:** wartość p -value = $1.45 \cdot 10^{-9}$ również jednoznacznie odrzuca hipotezę zerową.

Wyniki obu testów jednoznacznie potwierdzają, że wariancja składnika losowego nie jest stała, lecz rośnie w okresach wyższych przyrostów wydatków konsumpcyjnych oraz wyższych przyrostów stóp procentowych. Taka systematyczna zmienność wariancji stanowi ostateczne potwierdzenie konieczności zastosowania odpornych błędów standardowych (korekty barierowej HC3) w dalszej ocenie istotności zmiennych.

```
coeftest(model, vcov = vcovHC(model, type = "HC3"))
```

```
##
## t test of coefficients:
##
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)      0.2455077  0.0540392  4.5431 7.369e-06 ***
## Mortgage_rate      0.2445899  0.2071410  1.1808  0.2384
## Personal_consumption_expenditure -0.0102707  0.0018127 -5.6658 2.820e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Zastosowanie rygorystycznej korekty barierowej HC3 pozwoliło na ponowną ocenę istotności zmiennych w warunkach odpornych na heteroskedastyczność. Po przeliczeniu błędów standardowych zmienna Mortgage_rate okazała się statystycznie nieistotna (p -value 0.2384 > 0.1)

Testowanie współliniowości

```
vif(model)
```

```
##               Mortgage_rate Personal_consumption_expenditure
##               1.0029                      1.0029
```

Wartości wskaźnika VIF dla obu zmiennych są bliskie 1.


Korelacja między zmiennymi objaśniającymi po różnicowaniu

```
cor_objasnjace <- cor(train |>
  select(Mortgage_rate, Personal_consumption_expenditure))
print(round(cor_objasnjace, 4))
```

```
##               Mortgage_rate Personal_consumption_expenditure
## Mortgage_rate              1.0000                      0.0538
## Personal_consumption_expenditure 0.0538                      1.0000
```

```
ggplot(train, aes(x = Mortgage_rate,
                  y = Personal_consumption_expenditure)) +
  geom_point(alpha = 0.3, color = "grey") +
  geom_smooth(method = "lm", color = "red", se = TRUE) +
  labs(title = "Zależność między zmiennymi objaśniającymi",
       x = "Przyrost stopy kredytów hipotecznych",
       y = "Przyrost wydatków na konsumpcję") +
  theme_minimal()
```

```
## 'geom_smooth()' using formula = 'y ~ x'
```



Wykres rozrzutu między przyrostami stopy kredytów hipotecznych a przyrostami wydatków na konsumpcję nie wykazuje wyraźnej zależności liniowej — linia trendu jest niemal pozioma. Potwierdza to brak współliniowości między zmiennymi objaśniającymi, co jest zgodne z wartościami VIF bliskimi 1. Zmienne wnoszą do modelu niezależną informację.

Testowanie stabilności parametrów modelu

Test Chowa

```
test_chowa <- sctest(personal_savings ~ Mortgage_rate + Personal_consumption_expenditure,
                     type = "Chow",
```

```
point = 331,  
data = train)
```

```
test_chowa
```

```
##  
## Chow test  
##  
## data: personal_savings ~ Mortgage_rate + Personal_consumption_expenditure  
## F = 0.77567, p-value = 0.5081
```

Podczas testu Chowa należy podzielić obserwacje na dwa podokresy, a wybór podziału może przebiegać na różne sposoby. W tym wypadku obserwacje zostały podzielone na te przed kryzysem z 2008 roku i na te po tym kryzysie. Uzyskana wartość p-value = 0.51 jest wyższa od 0.1, co oznacza, że parametry modelu są stabilne.

Testowanie stabilności postaci analitycznej modelu

Test Ramsey'a RESET

```
resettest(model, power = 2:3, type = "fitted")
```

```
##  
## RESET test  
##  
## data: model  
## RESET = 2.7257, df1 = 2, df2 = 394, p-value = 0.06673
```

$0.06673 < 0.1$, odrzucenie H_0 o poprawnej postaci analitycznej modelu, sugeruje to obecność nieliniowości w relacjach między stopą oszczędności a zmiennymi makroekonomicznymi, co jest naturalną cechą długich szeregów czasowych.

Test liczby serii

```
runs.test(as.factor(model$residuals > 0))
```

```
##  
## Runs Test  
##  
## data: as.factor(model$residuals > 0)  
## Standard Normal = -1.2105, p-value = 0.2261  
## alternative hypothesis: two.sided
```


Test liczby serii weryfikuje niezależność kolejnych znaków reszt modelu, a wysokie p-value (0.2261) oznacza przyjęcie hipotezy zerowej o ich losowym rozkładzie.


```

model_data <- augment(model) |>
  mutate(date = train$date)

ggplot(model_data, aes(x = date, y = .resid)) +
  geom_line(color = "black", alpha = 0.7) +
  geom_hline(yintercept = 0, color = "red",
            linetype = "dashed", linewidth = 1) +
  geom_hline(yintercept = c(-2*sd(model$residuals),
                           2*sd(model$residuals)),
            color = "blue", linetype = "dotted") +
  labs(title = "Reszty modelu w czasie",
       x = "Data", y = "Reszta") +
  theme_minimal()

```



Zdecydowana większość reszt mieści się w przedziale, jednak widoczna jest zwiększona liczba obserwacji wykraczających poza ten przedział, co jest spójne z wcześniej wykrytą autokorelacją reszt. Szczególnie wyraźne skoki występują w okolicach lat 1986, 2008 i 2014, odpowiadających okresom turbulencji gospodarczych.

Badanie efektu katalizy

```

R0 <- cor(train |>
  select(Mortgage_rate, Personal_consumption_expenditure),

```

```

train$personal_savings)

R <- cor(train |>
  select(Mortgage_rate, Personal_consumption_expenditure),
  train |>
  select(Mortgage_rate, Personal_consumption_expenditure))
print(R < 0)

```

```

##                                Mortgage_rate Personal_consumption_expenditure
## Mortgage_rate                  FALSE                                     FALSE
## Personal_consumption_expenditure FALSE                                     FALSE

```

Okazuje się, że żadna ze zmiennych nie jest katalizatorem.

Badanie koïncydencji

```

koïncydencja <- function(x, y) {
  mean(sign(x) == sign(y), na.rm = TRUE)
}

zmienne <- train |>
  select(-date, -personal_savings)

wyniki_koïncydencji <- data.frame(
  Zmienna = names(zmienne),
  Koïncydencja = sapply(
    zmienne,
    function(x) koïncydencja(x, train$personal_savings)
  )
)

wyniki_koïncydencji

```

```


##                                Zmienna Koïncydencja
## Mortgage_rate                  Mortgage_rate    0.4686717
## Unemp_rate                      Unemp_rate      0.3458647
## NASDAQ                          NASDAQ          0.4185464
## Personal_consumption_expenditure Personal_consumption_expenditure 0.3383459

```

```

ggplot(wyniki_koïncydencji,
  aes(x = reorder(Zmienna, Koïncydencja),
    y = Koïncydencja)) +
  geom_col(fill = "#2C3E50") +
  coord_flip() +
  labs(
    title = "Współczynniki koïncydencji",
    x = "Zmienna",
    y = "Koïncydencja"
  ) +
  theme_minimal()

```



Otrzymane współczynniki koincydencji dla wszystkich analizowanych zmiennych są niższe od 0,5. Oznacza to, że zmienne objaśniające częściej zmieniają się w kierunku przeciwnym niż stopa oszczędności.

Ostateczna postać modelu

```
summary(model)
```

```
##
## Call:
## lm(formula = personal_savings ~ Mortgage_rate + Personal_consumption_expenditure,
##     data = train)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.2989 -0.2276  0.0209  0.2302  4.7623
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.245508   0.048269   5.086 5.65e-07 ***
## Mortgage_rate    0.244590   0.147124   1.662  0.0972 .
## Personal_consumption_expenditure -0.010271   0.001245  -8.252 2.34e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 0.7399 on 396 degrees of freedom
## Multiple R-squared:  0.1494, Adjusted R-squared:  0.1452
## F-statistic: 34.79 on 2 and 396 DF,  p-value: 1.205e-14
```

Ostatecznie model uwzględnia dwie zmienne: zmianę średniego oprocentowanie 30-letnich kredytów hipotecznych o stałej stopie procentowej oraz wydatków na konsumpcję. Obie zmienne są istotne statystycznie na poziomie $\alpha = 0.1$, co wynika z testu t-studenta. Na podstawie tych składników estymowana jest wartość zmiany kwoty jaką oszczędzają Amerykanie. Współczynnik determinacji wynosi 0.15, co jest satysfakcjonującym wynikiem przy modelowaniu tak złożonego zjawiska.

Interpretacja parametrów

Uzyskane parametry oznaczają, że Amerykanie:

- przy braku zmian w stopach procentowych kredytów hipotecznych oraz wydatkach na konsumpcję, zwiększają oszczędzaną kwotę o 0,246% swoich przychodów;
- gdy oprocentowanie kredytów hipotecznych rośnie o 1 punkt procentowy (ceteris paribus), zwiększają oszczędzaną kwotę o 0,245% swoich przychodów;
- gdy wydatki na konsumpcję rosną o 1\$ (ceteris paribus), zmniejszają oszczędzaną kwotę o 0,01% swoich przychodów.

Test Walda

```
linearHypothesis(model, c("Mortgage_rate = 0"), test = "F")
```

```
##
## Linear hypothesis test:
## Mortgage_rate = 0
##
## Model 1: restricted model
## Model 2: personal_savings ~ Mortgage_rate + Personal_consumption_expenditure
##
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1     397 218.32
## 2     396 216.80  1    1.5131 2.7638 0.09721 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
linearHypothesis(model, c("Personal_consumption_expenditure = 0"), test = "F")
```

```
##
## Linear hypothesis test:
## Personal_consumption_expenditure = 0
##
## Model 1: restricted model
## Model 2: personal_savings ~ Mortgage_rate + Personal_consumption_expenditure
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1     397 254.08
```

```
## 2      396 216.80  1      37.278 68.089 2.344e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Na podstawie testu Walda można uznać, że obie zmienne są istotne statystycznie na poziomie $\alpha = 0.1$.

Wyznaczenie prognozy

```
test_diff <- test |>
  select(-c(CPI, disposable_income))
last_train <- tail(train, 1)
test_diff <- rbind(last_train, test_diff)
test_diff <- test_diff |>
  mutate(across(where(is.numeric), ~ c(NA, diff(.x)))) |>
  slice(-1)

predicted <- predict(model, newdata = test_diff)
predicted_lvl <- last_train$personal_savings + cumsum(predicted)

wykres_df <- data.frame(
  index = 1:nrow(test),
  realne = test$personal_savings,
  prognozowane = predicted_lvl
)
wykres_df <- wykres_df |>
  pivot_longer(
    cols = c(realne, prognozowane),
    names_to = "typ",
    values_to = "wartosc"
  )
ggplot(wykres_df, aes(x = index, y = wartosc, color = typ)) +
  geom_line() +
  theme_minimal()
```



Błąd prognozy

```
ex_post <- mean(  
  abs(test$personal_savings - predicted_lvl) /  
  abs(test$personal_savings)  
) * 100
```

Względny błąd prognozy EX POST wyniósł 1700.92%. Jest to wynik bardzo duży i może mieć wiele przyczyn takich jak niska jakość modelu, co ma odzwierciedlenie w R^2 na poziomie zaledwie 0.15. Mogły zostać również popełnione błędy przy implementacji modelu. Należy zauważyć, że np. nie udało się usunąć autokorelacji reszt.